

**LAPORAN PROYEK PENGOLAHAN SINYAL DIGITAL
PENGEMBANGAN SISTEM SPEECH-TO-TEXT BAHASA
INDONESIA BERBASIS PENGOLAHAN SINYAL DIGITAL**



Oleh:

Faishal Bayu Pratama (23031554092)

Mutiara Restu Aulya (23031554113)

Yogi Ramadhani (23031554198)

Sains Data 2023D

PROGRAM STUDI SAINS DATA

FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM

UNIVERSITAS NEGERI SURABAYA

1. Pendahuluan

1.1. Latar Belakang

Teknologi pengenalan suara memainkan peran yang semakin penting di era digital. Aplikasi seperti asisten virtual, pencarian berbasis suara, dan sistem navigasi telah menjadi kebutuhan sehari-hari. Namun, kebanyakan sistem speech-to-text yang ada saat ini lebih memfokuskan pada Bahasa Inggris, sedangkan Bahasa Indonesia dengan kompleksitas fonetik dan gramatikalnya masih kurang mendapat perhatian. Hal ini menciptakan kesenjangan teknologi yang signifikan, terutama bagi pengguna yang berkomunikasi dalam Bahasa Indonesia.

Selain itu, kebutuhan akan sistem yang mampu bekerja secara real-time menjadi semakin penting, baik untuk layanan publik seperti layanan pelanggan maupun dalam dunia pendidikan untuk membantu aksesibilitas. Teknologi pengolahan sinyal digital menawarkan solusi yang efektif untuk meningkatkan akurasi dan efisiensi dalam mengenali ucapan Bahasa Indonesia. Oleh karena itu, proyek ini mengembangkan sistem speech-to-text dengan membandingkan dua metode, yaitu Whisper.ai dan LSTM, untuk menemukan pendekatan terbaik dalam pengenalan suara Bahasa Indonesia.

1.2. Tujuan

1. Mengembangkan sistem speech-to-text Bahasa Indonesia.
2. Membandingkan performa Whisper.ai dengan model LSTM untuk pengenalan suara Bahasa Indonesia.

1.3. Manfaat

1. Mempermudah pengguna dalam mengonversi ucapan ke teks untuk kebutuhan komunikasi atau dokumentasi.
2. Mendorong pengembangan teknologi lokal berbasis Bahasa Indonesia.

1.4. Dataset

Dataset yang digunakan dalam penelitian ini berasal dari [Common Voice Mozilla](#), yang berisi rekaman suara Bahasa Indonesia sebanyak 3.618 sampel. Dataset ini mencakup berbagai variasi aksen dan intonasi, yang sangat relevan untuk melatih model pengenalan suara yang mampu menangani keragaman Bahasa Indonesia. Selain rekaman suara, dataset ini juga mencakup transkrip dari setiap rekaman, yang digunakan sebagai label dalam proses pelatihan model.

2. Metode

2.1. Pengumpulan Data

Dataset yang digunakan adalah kumpulan rekaman suara Bahasa Indonesia dari Common Voice Mozilla, yang mencakup 3.618 rekaman suara dengan transkrip. Dataset ini mencakup variasi aksen dan intonasi untuk memastikan representasi yang luas. Dua metode digunakan untuk memproses data, yaitu:

- a. Model berbasis LSTM : Pelatihan dan pengenalan kata dari rekaman suara.
- b. Model Whisper : Transkripsi otomatis audio menggunakan model pretrained.

2.2. Ekstraksi Fitur dan Reduksi Noise (LSTM)

Pada metode berbasis LSTM, fitur audio diekstraksi menggunakan Mel Frequency Cepstral Coefficients (MFCC) dan dilengkapi dengan pengurangan noise untuk meningkatkan kualitas sinyal:

- a. Ekstraksi MFCC : Representasi numerik audio dengan padding untuk memastikan konsistensi panjang fitur.
- b. Reduksi Noise : Menghapus sinyal amplitudo rendah menggunakan ambang batas berbasis maksimum amplitudo audio.

2.3. Persiapan Dataset (LSTM)

Dataset diproses dengan membagi setiap kalimat menjadi kata-kata individual. Fitur yang diekstraksi dari file audio dipasangkan dengan kata-kata yang sesuai. Selanjutnya, dataset dibagi menjadi data pelatihan dan data uji dengan rasio 80:20 untuk memastikan evaluasi model yang adil.

2.4. Pembangunan dan Pelatihan Model LSTM

Model LSTM dirancang dengan lapisan masking untuk menangani panjang input yang bervariasi, lapisan LSTM dengan 128 unit, dan lapisan Dense dengan fungsi aktivasi softmax untuk prediksi. Model dilatih menggunakan optimizer Adam dan loss sparse_categorical_crossentropy selama 10 epoch dengan batch size 32.

2.5. Transkripsi Audio dengan Whisper

Selain LSTM, Whisper.ai digunakan untuk mentranskripsi file audio langsung ke teks. Model Whisper yang digunakan adalah model pretrained "base" yang mendukung bahasa Indonesia, sehingga tidak memerlukan pelatihan tambahan.


2.6. Evaluasi Model

Metode evaluasi dilakukan secara terpisah:

1. Model LSTM : Akurasi dihitung menggunakan data uji untuk mengukur performa model dalam mengenali kata.
2. Whisper : Hasil transkripsi dievaluasi secara manual untuk membandingkan akurasi transkripsi dengan data referensi.

3. Hasil dan Pembahasan

Kami menggunakan sound sample untuk menguji coba dari kedua model dengan file wav yaitu Coba.wav dengan durasi 4.80 detik dengan isi transkrip “**Aku Suka Bola**”




Visualisasi sinyal audio bermanfaat untuk menganalisis struktur sinyal, seperti durasi, pola amplitudo, dan kemungkinan adanya kebisingan. Berdasarkan grafik di atas, sinyal audio memiliki beberapa puncak amplitudo yang mengindikasikan bagian dengan intensitas suara yang lebih tinggi.

3.1 Whisper

Whisper adalah model *speech-to-text* yang mendukung berbagai bahasa. Pada kasus ini, model **berhasil** mengenali kata-kata dalam bahasa Indonesia dari file audio yang kami berikan. Model "base" yang digunakan memiliki kecepatan dan akurasi yang cukup baik untuk tugas transkripsi sederhana. Model ini mengubah input audio menjadi log-Mel spectrogram untuk merepresentasikan frekuensi suara sesuai persepsi manusia. Dengan arsitektur Encoder-Decoder Transformer, Whisper memproses spectrogram menjadi representasi fitur melalui encoder dan menghasilkan teks transkripsi secara autoregressive melalui decoder. Whisper dilatih menggunakan dataset multibahasa yang mencakup 680.000+ jam audio, memungkinkan kemampuan pengenalan lebih dari 90 bahasa serta ketahanan terhadap noise. Model ini juga mendukung timestamping, identifikasi bahasa, dan memiliki akurasi tinggi berkat data pelatihan yang besar. Namun, penggunaan Whisper membutuhkan sumber daya komputasi tinggi dan kurang cocok untuk aplikasi real-time.

3.2 LSTM

Pada implementasi Long Short-Term Memory (LSTM) untuk pengenalan suara (*speech recognition*), hasil yang diperoleh menunjukkan performa model yang tidak memadai. Output transkripsi model untuk audio dengan suara asli berbunyi "aku suka bola" memberikan hasil yang **tidak sesuai**, yaitu "**pada**". Selain itu, akurasi model sangat rendah, hanya mencapai 4%.



grafik diatas merupakan waveform dari sound sample yang telah dilakukan fitur denoised.

Hasil implementasi LSTM untuk speech recognition menunjukkan kinerja yang kurang memadai, dengan akurasi sangat rendah (4%) dan hasil transkripsi yang tidak sesuai. Misalnya, audio dengan suara "aku suka bola" malah ditranskripsi menjadi "pada". Hal ini disebabkan oleh beberapa faktor, seperti dataset yang kurang representatif, fitur audio yang tidak optimal, serta model yang mungkin terlalu sederhana atau tidak sesuai untuk data yang kompleks. Selain itu, proses denoise audio dan prepare dataset memakan waktu lama karena algoritma yang kurang efisien dan dimensi data yang besar. Keterbatasan LSTM, seperti pemrosesan data secara sekuensial dan kebutuhan perangkat keras yang mumpuni, juga menjadi kendala.

3.3 Perbandingan

Aspek	LSTM	Whisper
Arsitektur Model	Long Short-Term Memory (LSTM), model sekuensial berbasis RNN yang memproses data secara urut.	Transformer-based model dengan arsitektur modern, dirancang untuk tugas-tugas beragam.
Akurasi	Sangat rendah (4%), hasil transkripsi tidak sesuai.	Tinggi, mampu mengenali teks dengan baik dari audio.
Kebutuhan Dataset	Memerlukan dataset besar yang seimbang dan berkualitas tinggi untuk hasil optimal.	Sudah dilatih pada dataset besar, dapat digunakan langsung tanpa pelatihan ulang.
Proses Denoising Audio	Manual, membutuhkan algoritma tambahan dan waktu lama.	Tidak diperlukan, Whisper menangani berbagai kualitas audio secara langsung.
Kecepatan Proses	Lambat, terutama pada proses <i>denoise</i> dan ekstraksi fitur.	Cepat, terutama pada perangkat keras yang mendukung (GPU).
Kemampuan Multibahasa	Terbatas, perlu pelatihan ulang untuk bahasa tertentu.	Mendukung berbagai bahasa secara bawaan, termasuk Bahasa Indonesia.
Kemampuan Generalisasi	Sulit menangani variasi suara dan aksen tanpa pelatihan tambahan.	Unggul, mampu menangani variasi suara, aksen, dan kualitas audio dengan baik.
Kemudahan Implementasi	Membutuhkan banyak langkah manual seperti <i>feature extraction</i> dan denoising.	Mudah digunakan dengan fungsi bawaan yang langsung menghasilkan transkripsi.
Kebutuhan Perangkat Keras	Bisa berjalan di CPU, tetapi lambat; membutuhkan GPU untuk efisiensi.	Dapat berjalan di CPU, tetapi optimal di GPU untuk performa tinggi.
Output Transkripsi	Tidak sesuai dengan input audio ("aku suka bola" menjadi "pada").	Akurat, sesuai dengan isi audio ("aku suka bola").

4. Kesimpulan

Proyek ini telah berhasil mengembangkan sistem speech-to-text untuk bahasa Indonesia dengan membandingkan performa model whisper dan LSTM. Hasil evaluasi menunjukkan bahwa whisper memiliki akurasi yang sangat tinggi, cepat dalam proses transkripsi, dan mampu menangani berbagai aksentuasi serta kualitas audio tanpa memerlukan pelatihan tambahan. Whisper unggul dalam fleksibilitas penggunaan, terutama untuk aplikasi voice recognition real time, meskipun membutuhkan perangkat keras yang lebih mumpuni. Sebaliknya, model LSTM menunjukkan kinerja yang kurang memadai dengan akurasi yang rendah hanya sebesar 4% dan hasil transkripsi yang tidak sesuai. Model ini memerlukan proses ekstraksi fitur dan reduksi noise manual yang memakan waktu lama, serta membutuhkan dataset yang lebih representatif dan berkualitas untuk hasil optimal.

Berdasarkan hasil yang didapatkan, Whisper direkomendasikan untuk digunakan dalam implementasi sistem speech-to-text Bahasa Indonesia, khususnya untuk kebutuhan real-time yang membutuhkan akurasi dan efisiensi tinggi. Namun, pengembangan model LSTM dapat dilakukan dengan cara memperbaiki kualitas dataset, meningkatkan kompleksitas arsitektur model, perangkat keras yang memadai, dan mengoptimalkan proses preprocessing untuk meningkatkan akurasi. Dengan langkah-langkah ini, LSTM dapat menjadi alternatif yang lebih bagus dalam pengenalan suara berbasis Bahasa Indonesia.

5. Referensi

- Pratama, R. S. A., & Amrullah, A. (2024). ANALYSIS OF WHISPER AUTOMATIC SPEECH RECOGNITION PERFORMANCE ON LOW RESOURCE LANGUAGE. *Jurnal Pilar Nusa Mandiri*, 20(1), 1–8. <https://doi.org/10.33480/pilar.v20i1.4633>
- Wang, S., Yang, C. H., Wu, J., & Zhang, C. (2023). Can Whisper perform speech-based in-context learning. *arXiv (Cornell University)*. <https://doi.org/10.48550/arxiv.2309.07081>
- Zeyer, A., Doetsch, P., Voigtlaender, P., Schluter, R., & Ney, H. (2017). A comprehensive study of deep bidirectional LSTM RNNs for acoustic modeling in speech recognition. *2017 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 2462–2466. <https://doi.org/10.1109/icassp.2017.7952599>

6. Lampiran

Source code:

https://colab.research.google.com/drive/1OEExsYG20tErJRupxHzanYGnUZwx8nrD?usp=sharing#scrollTo=tDGzm1MgiZ_X

Dataset:

wav : 📁 wav suara

path : 📁 path

audio : 📄 Coba.wav

